Introducción a Apache Hadoop

Francisco Javier Sueza Rodríguez

29 de octubre de 2026

Centro: IES Zaidin-Vergeles
Curso: Inteligencia Artificial y Big Data
Módulo: Big Data Aplicado

Índice

1 Creación de la Máquina Virtual **4**
1.1 Solución 4

2 Configuración del Nombre del Equipo y Preparación del Sistemas **6**
2.1 Solución 6

3 Creación del Usuario Hadoop **7**
3.1 Solución 7

4 Configuración de SSH **8**
4.1 Solución 8

5 Instalación de Apache Hadoop **9**
5.1 Solución 10

Referencias **11**

Índice de figuras

1.1 Configuración General de la Imagen 4
1.2 Configuración de CPU/RAM de la Imagen 5
1.3 Configuración del Alamacenamiento y de Red de la Imagen 5
1.4 Primer inicio de Ubuntu Server 6
2.1 Ejecución de los comandos hostname y hostnamectl 6
2.2 Versión de Java instalada 7
3.1 Prompt con el usuario y el hostname 7
4.1 Generación de las claves de ssh 8
4.2 Contenido del fichero autorized_keys 8
4.3 Conexión mediante ssh a localhost 9
4.4 Conexión empleando el host nodo1-fjsr-26-27 9
5.1 Directorio de instalación de Hadoop 10
5.2 Valores de las variables de entorno 10
5.3 Versión de Hadoop instalada 10

1. Creación de la Máquina Virtual

Crea en Oracle VirtualBox una máquina virtual con Ubuntu Server 26.04 LTS, 2 procesadores virtuales, 8 GB de RAM, 100 GB de almacenamiento y una configuración de red que permita acceso a Internet y a las interfaces web de Hadoop desde el equipo anfitrión.

1.1. Solución

En este primer ejercicio se va a proceder a instalar **Ubunut Server 26.04.1** en una máquina virtual de **VirtualBox**, la cual se ha instalado en el sistema operativo del host, que es una **Kubuntu 26.04.1**, y se ha creado una imagen usando es especificaciones indicadas.

En primer lugar se ha creado la imagen con el nombre **practica1-bda**, esto no estaba especificado en la practica por lo que se ha elegido este para dejar claro su propósito. La imagen se ha creado casi de forma automática, solo especificando algunos datos durante el proceso.

Se ha creado el **usuario hadoop**, tal y como se especificaba en el enunciado, pero la ir a crear le **hostname** con las indicaciones dadas ha surgido un problema, y es que Linux **no admite la barra baja** (_) como carácter para nombrar el hostname, por lo que sea ha sustituido por la barra media. Eso se debe a que según el estándar [1], no se puede emplear este carácter para el hostname.

En la siguiente captura se puede ver la configuración general generada después de crear la imagen:

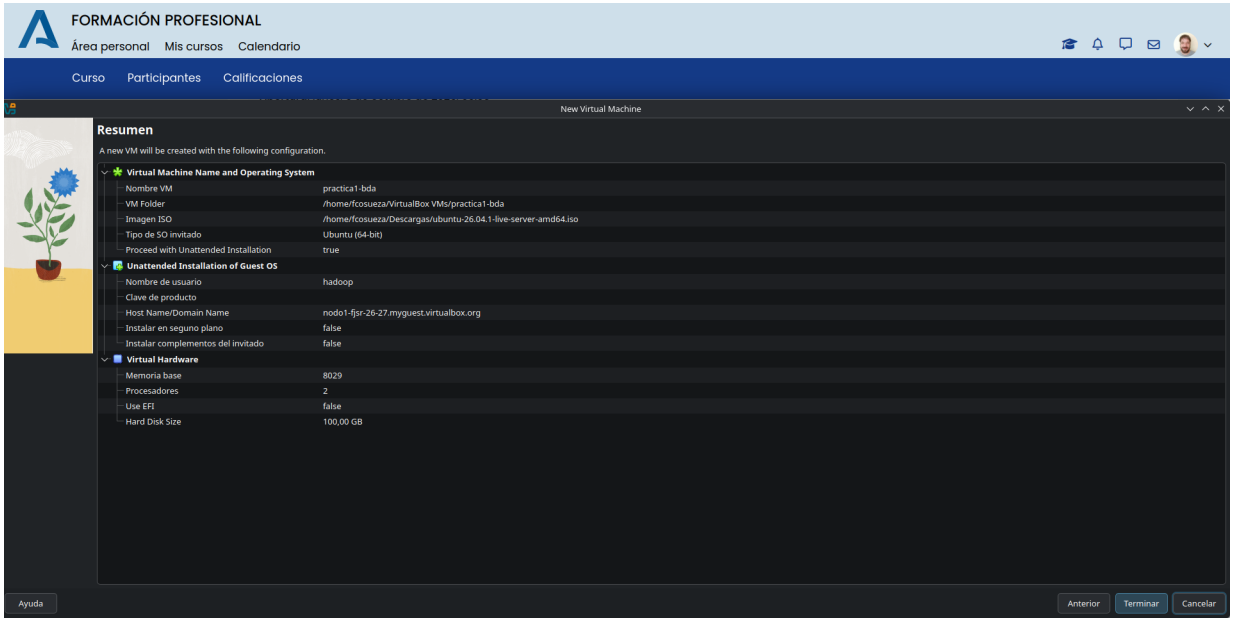


Figura 1.1: Configuración General de la Imagen

Después de realizar la configuración general, se ha elegido el **número de CPUs** que queremos que tenga la imagen, que este caos han sido 2, y la **cantidad de RAM** que va a tener la máquina virtual, que va a ser un total de **8 GB**, tal y como se especifica en el enunciado.

En la siguiente captura, tomada durante el proceso de creación, se puede ver esta información:

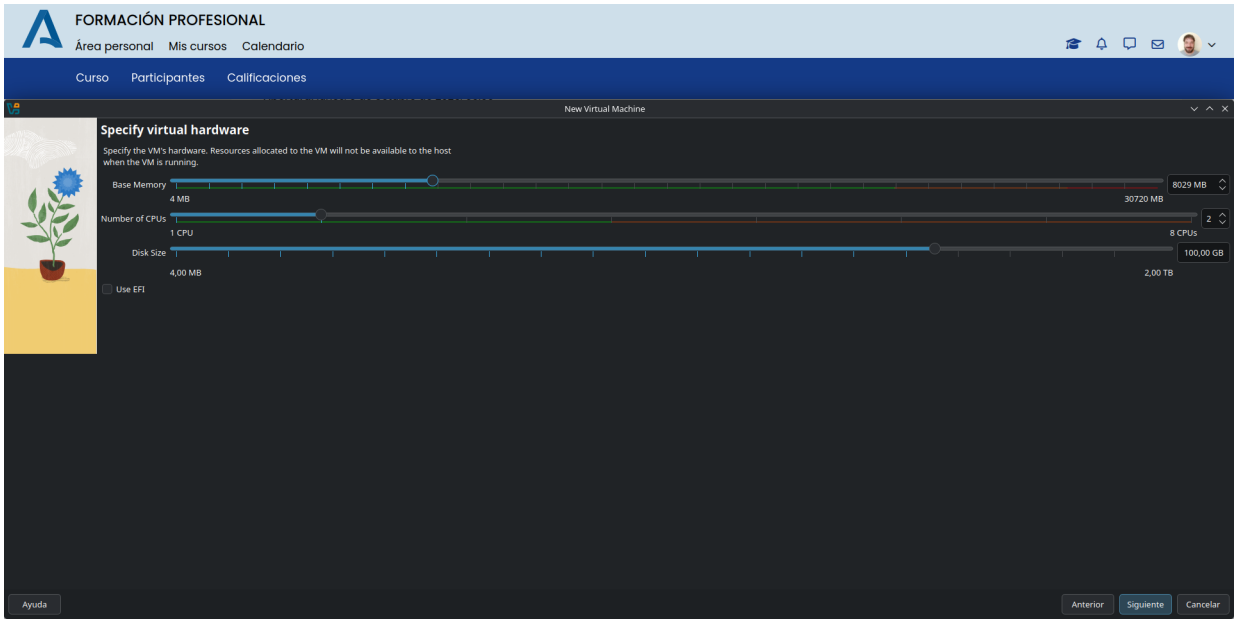


Figura 1.2: Configuración de CPU/RAM de la Imagen

También se ha seleccionado **100 GB de almacenamiento**, como podemos ver en la primera captura. El resto de la configuración se ha creado de forma automática, durante el proceso de creación de la imagen, como por ejemplo, el adaptador de red que se usa. En la siguiente captura, podemos ver la configuración creada tanto del Almacenamiento como de red:

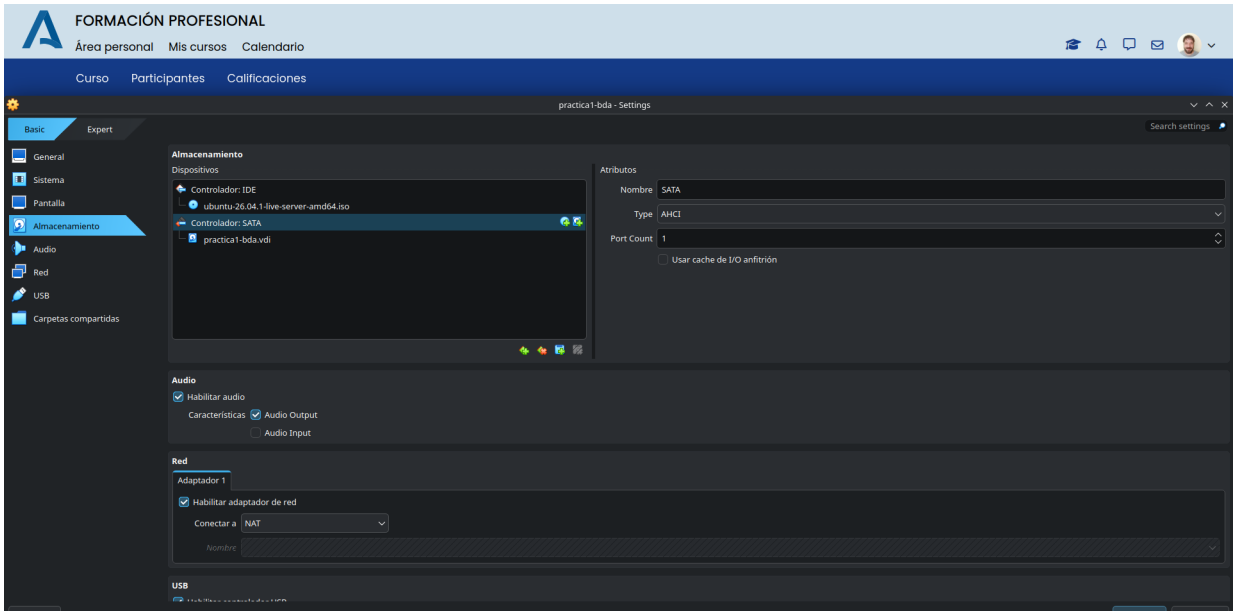


Figura 1.3: Configuración del Alamacenamiento y de Red de la Imagen

Como podemos ver, ha configuración la conexión de red automáticamente con **NAT**, así como el controlador SATA para el almacenamiento.

Una vez realizada la configuración, se ha **instalado Ubuntu Server** en la máquina virtual. Una vez realizada la instalación, se ha **iniciado Ubuntu Server** por primera, como podemos ver a continuación:

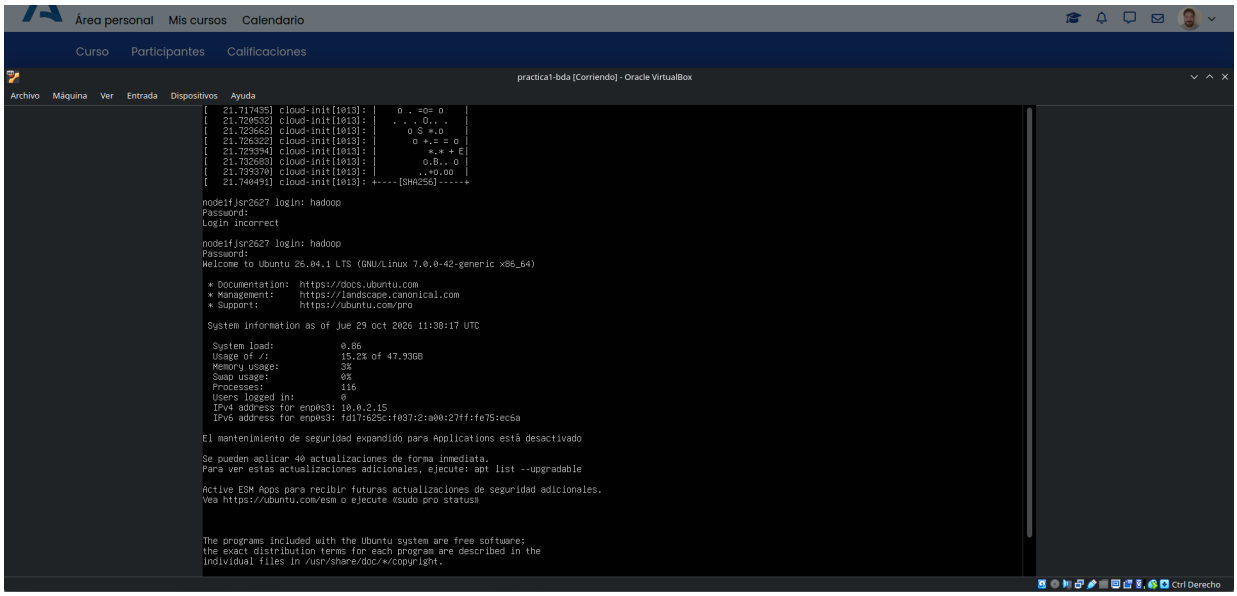


Figura 1.4: Primer inicio de Ubuntu Server

2. Configuración del Nombre del Equipo y Preparación del Sistemas

Configura el nombre del nodo con el formato **nodo1_iniciales_26_27**, compruébalo con **hostname** y **hostnamectl**, actualiza el sistema, verifica la conectividad e instala Java. Explica por qué Hadoop necesita Java y la función de **JAVA_HOME**.

2.1. Solución

Como se comentaba en el punto anterior, **ni Linux**, **ni VirtualBox permiten** los nombres de host con **guiones bajos**, así que se ha optado por reemplazar los guiones bajos por guiones medios, para evitar conflictos. En la siguiente captura, podemos ver la ejecución de los comandos **hostname** y **hostnamectl**.

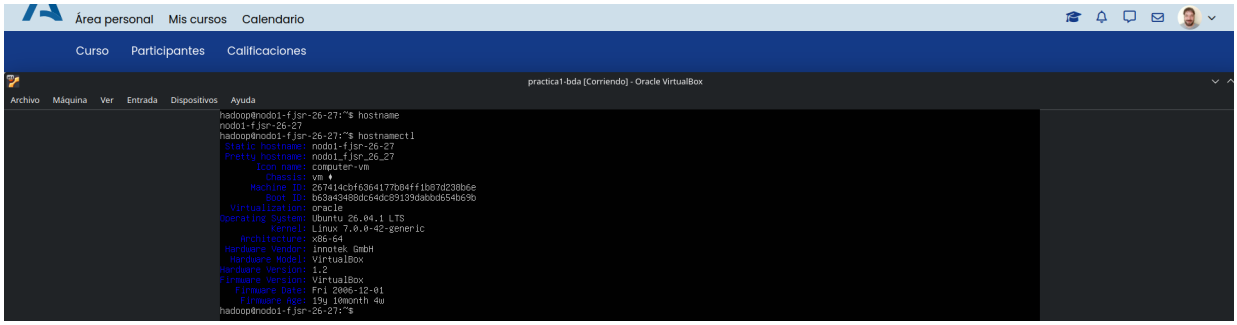


Figura 2.1: Ejecución de los comandos hostname y hostnamectl

A continuación se ha actualizado el sistemas, empleando el comando **sudo apt-get update** y se ha procedido a instalar Java, mediante los paquetes **default-jre** y **default-jdk**, que se han instalado sin problemas. En la siguiente captura, podemos ver la versión instalada de Java:

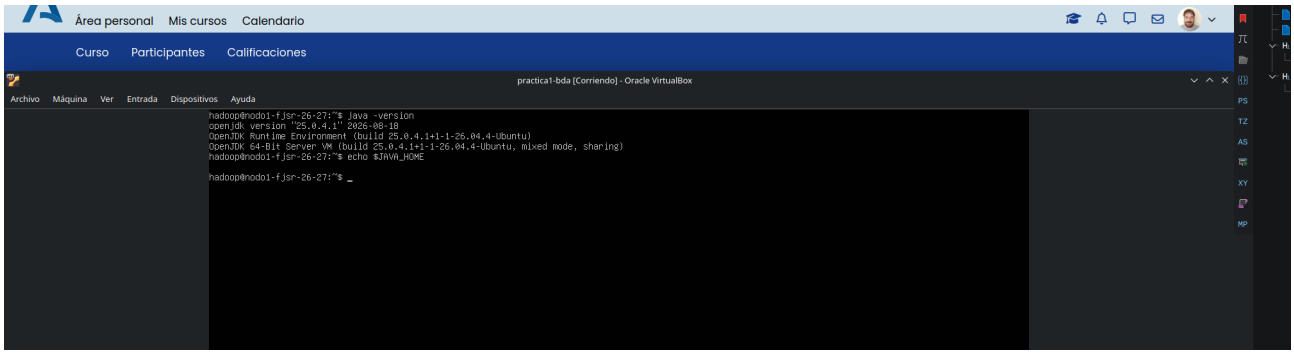


Figura 2.2: Versión de Java instalada

El motivo por que Hadoop es porque **esta desarrollado en Java**, especialmente las librerías principales del proyecto, aunque hay otros lenguajes que se incluyen en otras aplicaciones del ecosistemade Hadoop [2]. Respecto a **JAVA_HOME**, es una variable de entorno importante, ya que apunta al **entorno de ejecución de JAVA**, o **JRE** (Java Runtime Environment).

3. Creación del Usuario Hadoop

Crea el usuario **hadoop**, su directorio personal, configura los permisos necesarios y accede con dicho usuario. El prompt debe tener un formato similar a **hadoop@nodo1_abs_26_27: $**.

3.1. Solución

El usuario hadoop **se ha creado** durante el proceso de **instalación**, por lo que no ha sido necesario crearlo ahora, aunque hubiera sido sencillo usando el comando **adduser**, pero no ha sido necesario. En la siguiente captura se puede ver el prompt correcto.

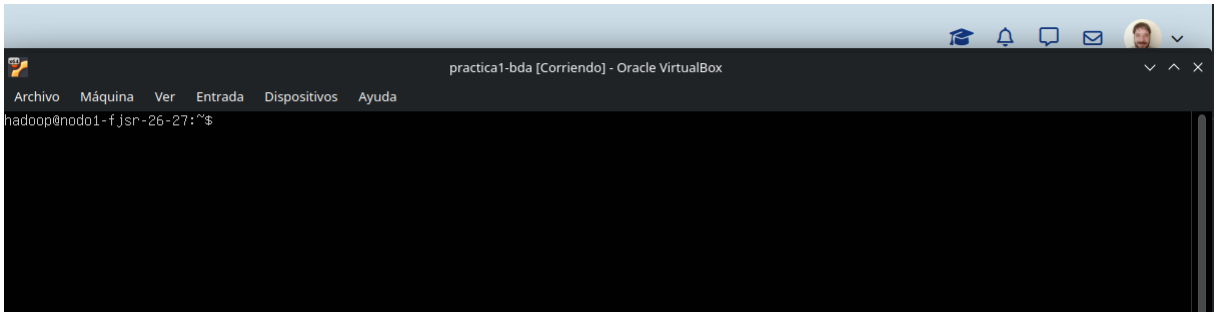


Figura 3.1: Prompt con el usuario y el hostname

4. Configuración de SSH

Instala y configura SSH para que el usuario **hadoop** pueda conectarse sin contraseña mediante clave pública. Prueba **ssh localhost** y **ssh nodo1_iniciales_26_27**. Explica por qué Hadoop utiliza SSH.

4.1. Solución

En este ejercicio vamos a configurar SSH. **Hadoop** necesita ssh ya que este permite la conexión, de forma segura, a todos los nodos de la red distribuida. De esta forma el framework puede realizar operaciones en dichos nodos de forma segura, y aunque nosotros solo vamos a tener un nodo real, vamos a simular una red distribuida, así que necesitamos instalarlo.

No se ha instalado ssh ya que esto se ha realizado durante la instalación. En primer lugar se **han generado las claves** usando el comando **ssh-keygen**, para posteriormente introducir la clave en el fichero **autorized_keys** y cambiar los permisos para que todo funcione correctamente. A continuación se muestran las capturas con la configuración inicial.

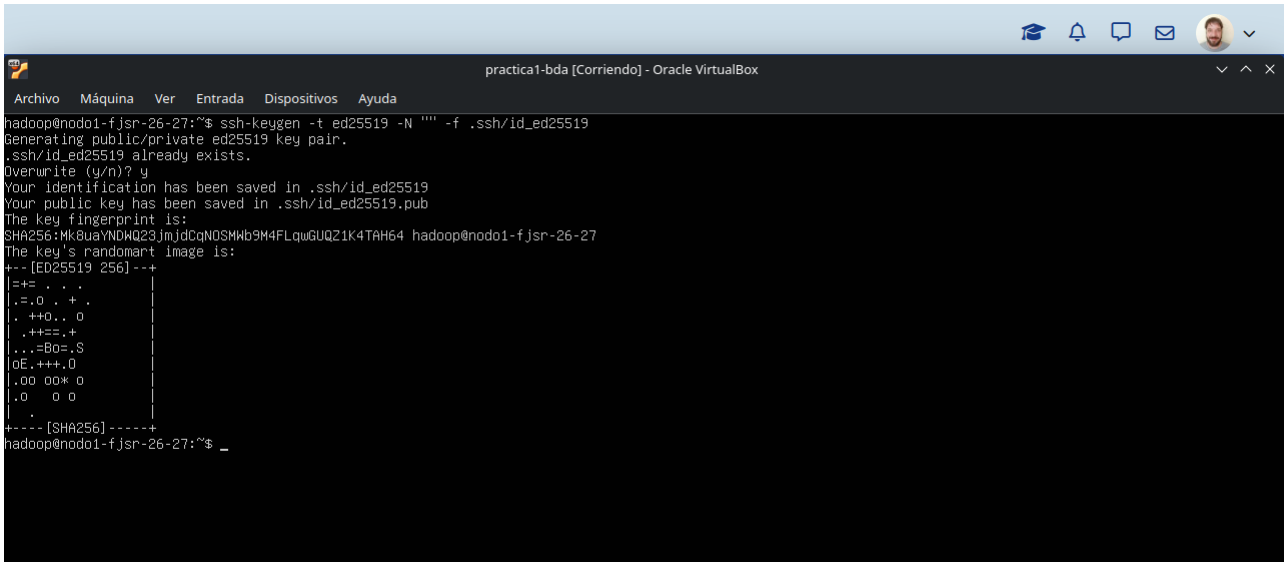


Figura 4.1: Generación de las claves de ssh

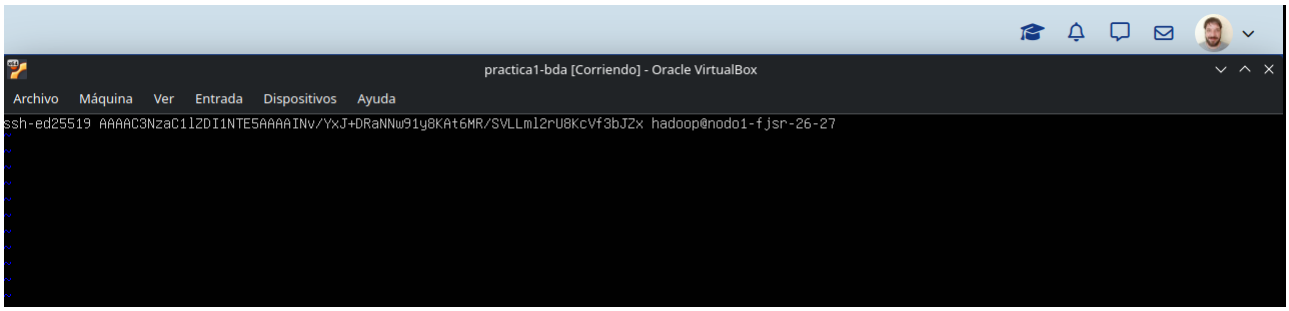


Figura 4.2: Contenido del fichero autorized_keys

Una vez configurado todo, se ha comprobado que funciona correctamente realizando la conexión al sistema empleando los 2 hosts especificados en el enunciado.

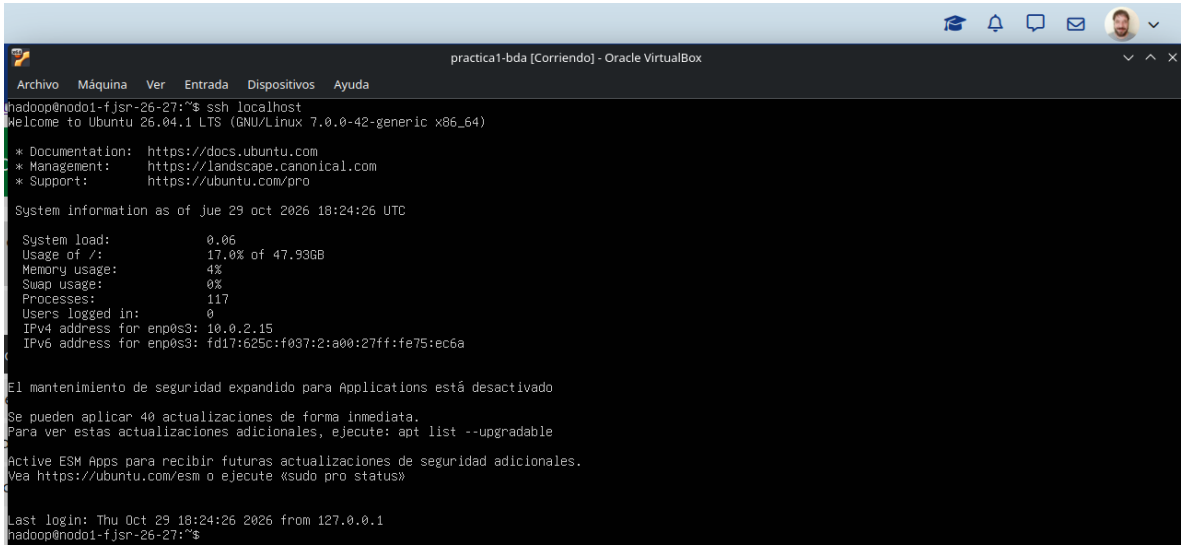


Figura 4.3: Conexión mediante ssh a localhost

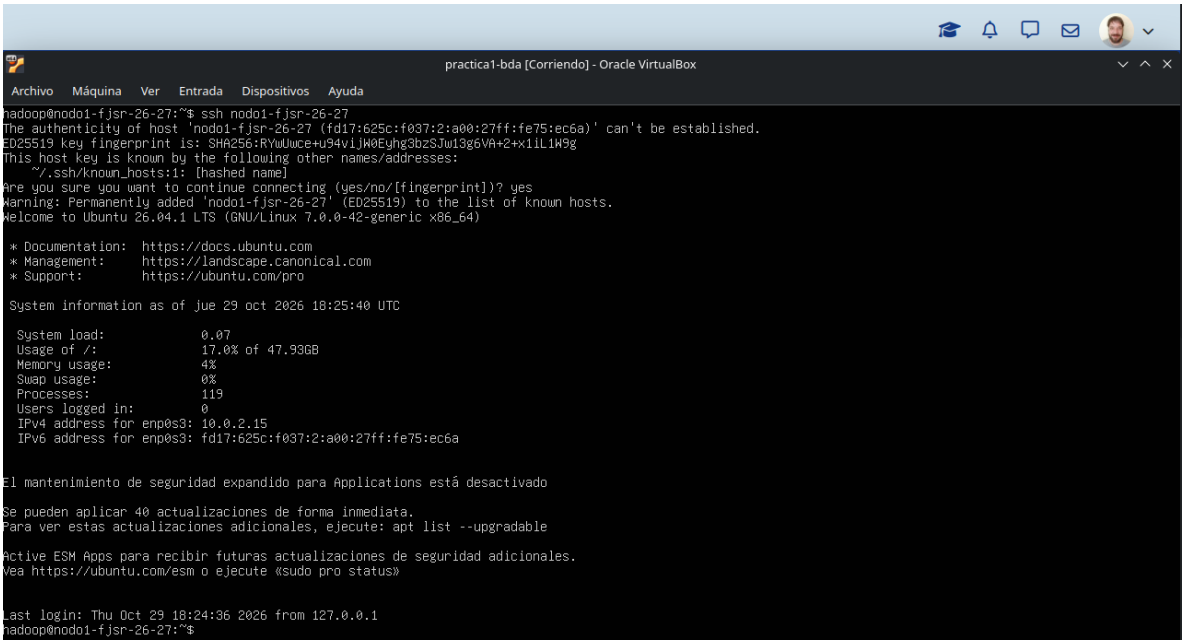


Figura 4.4: Conexión empleando el host nodo1-fjsr-26-27

5. Instalación de Apache Hadoop

Descarga e instala Apache Hadoop en **/opt/hadoop**. Configura **JAVA_HOME**, **HADOOP_HOME**, **HADOOP_CONF_DIR** y **PATH**. Comprueba la instalación con **hadoop version**.

5.1. Solución

En este ejercicio vamos a **instalar Hadoop** y a configurar las variables de entorno para su correcto funcionamiento. Para realizar la instalación, se ha elegido la **distribución binaria** que podemos encontrar en la página de descargar de Hadoop, mediante **wget**, ya que no tenemos interfaz gráfica, y se ha extraído en **/opt**. En la siguiente captura podemos ver el directorio de instalación de Hadoop.

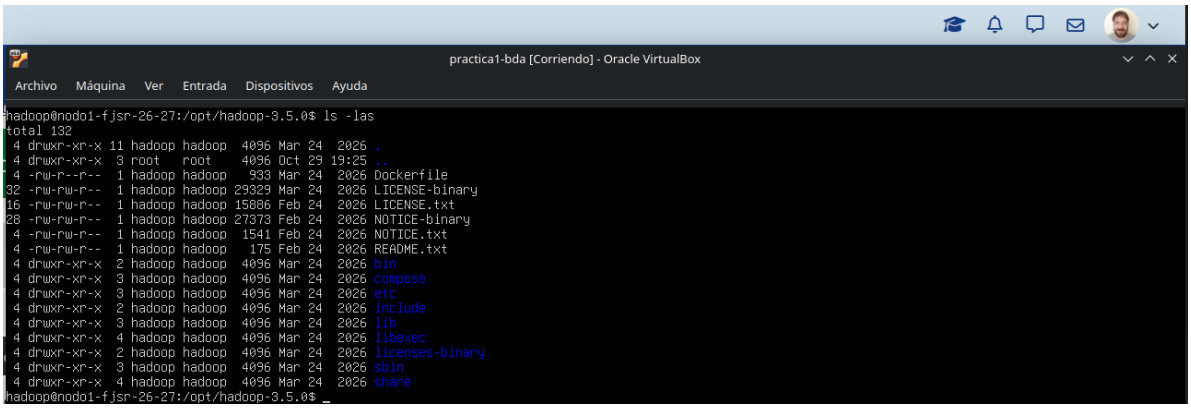


Figura 5.1: Directorio de instalación de Hadoop

A continuación se han establecido todas las variables de entorno para que Hadoop pueda funcionar correctamente, lo que se ha hecho incluyéndolas en el fichero **.bashrc** del directorio home del usuario. Por último, se ha comprobado que la versión de Hadoop es la correcta, como podemos ver en las siguientes capturas.



Figura 5.2: Valores de las variables de entorno



Figura 5.3: Versión de Hadoop instalada

6. Configuración Pseudo-distribuida

Configura **core-site.xml**, **hdfs-site.xml**, **mapred-site.xml** y b para trabajar en modo pseudo-distribuido. Explica la función de cada fichero y justifica **dfs.replication = 1**.

6.1. Solución

Referencias

[1] RFC 1123.
https://www.rfc-editor.org/info/rfc1123/.

[2] IBM HDFS.
https://www.ibm.com/think/topics/hdfs.