Sistemas de Big data

Francisco Javier Sueza Rodríguez

7 de noviembre de 2026

Centro: IES Zaidin-Vergeles
Curso: Inteligencia Artificial y Big Data
Asignatura: Sistemas de Big Data

Índice

1 Introducción a Big Data **4**
1.1 Por qué Big Data . . . 4
1.1.1 Las 5 Vs . . . 4
1.1.1.1 Volumen . . . 4
1.1.1.2 Velocidad . . . 6
1.1.1.3 Variedad . . . 6
1.1.1.4 Veracidad . . . 7
1.1.1.5 Valor . . . 7
1.1.2 Que Conseguimos Gracias al Big Data . . . 8
1.1.2.1 Desde los Eventos al Valor . . . 8
1.2 Clusters de Computadoras . . . 9
1.3 Conceptos de Almacenamiento de Datos . . . 10
1.3.1 Bases de Datos Relacionales . . . 10
1.3.2 Dataset . . . 10
1.3.3 Almacén de Datos . . . 11
1.3.4 ACID . . . 11
1.3.5 Teorema CAP . . . 12
1.3.6 BASE . . . 13
1.4 Conceptos de Procesamiento de Datos . . . 13
1.4.1 Procesamiento en Paralelo . . . 13
1.4.2 Procesamiento Distribuido . . . 14
1.4.3 Estrategias de Procesamiento de Datos . . . 15
1.5 OLTP . . . 16
1.5.1 OLAP . . . 16
1.6 Principio SCV . . . 17
1.7 Arquitectura por Capas de Big Data . . . 17
1.8 Panorama del Big Data . . . 19

Glosario **21**

Referencias **22**

Índice de figuras

1.1 Unidades de cantidad de información 5
1.2 Capas de un sistema Big Data 19
1.3 Panorama del Big Data 19

Índice de tablas

1. Introducción a Big Data

En esta primera unidad vamos a realizar una **introducción al Big Data**. Comenzaremos entendiendo cuales han sido las circunstancias del surgimiento del Big Data. Veremos también que son los clústeres de computadoras, que forma la infraestructura básica de los sistemas de Big Data.

Además, veremos conceptos muy importantes para entender el fenómeno del Big Data. Finalmente ver la arquitectura en capas que se utiliza en en proyecto de Big Data hoy en día.

1.1. Por qué Big Data

En una empresa o institución, la **cantidad de datos** que se generan pueden llegar a ser enormes. Si la cantidad de datos es muy enorme, los **métodos tradicionales** pueden **no ser suficientes** para gestionar, de forma eficiente estos datos. Aquí es donde entra en juego el **Big Data**, un conjunto de tecnologías y metodologías que permiten gestionar grandes cantidades de datos de forma más eficiente, y en esta sección vamos a ver las características que lo hacen necesario.

1.1.1. Las 5 Vs

En esta sección vamos a ver las **cinco características** de Big Data que suelen usarse para discernir si el procesamiento de datos que necesitamos realizar puede realmente considerarse como Big Data.

Esas 5 características se llaman "**las 5 Vs**z se componete de: **volumen**, **velocidad**, **variedad**, **veracidad** y **valor**. A continuación, vamos a describir con más detalle estas características.

1.1.1.1. Volumen

La primera característica de reto del Big Data es el **gran volumen de datos** que hay que procesar, es decir, la cantidad de bytes de información que hay que tratar.

En los últimos tiempos, la **cantidad de información** que hay que procesar ha ido creciendo de forma exponencial, ya todo esta digitalizado, los usuarios interactúan de forma online con las administraciones, las empresa tiene que almacenar datos de sus clientes o usuarios, ...etc. Para que nos hagamos la idea de la magnitud de esta cantidad de datos, podemos ver una tabla en la Figura 1.1 donde se muestran todas las magnitudes que miden la cantidad de información.

Hay que tener en cuenta que si bien el significado de un kilobyte (KB) es de 1000 bytes, dado que en ambientes computacionales se emplea constantemente la numeración en base 2, existe el **kibibyt** (KiB), el cual corresponde a 1024 bytes (2^{10}). De igual modo también existe el **mebibyte** (MiB = 2^{20}), **gibibyte** (GiB = 2^{30}), y así toda la progresión hasta llegar al **yobibyte** (YiB = 2^{80}).

Lo que puede producir cierta confusión es que por lo general se suele usar la nomenclatura en base 10 de forma indistinta, para referirse tanto a la base 10 como la base 2. Es decir, cuando vemos 1 MB, ses posible que signifique 10^6 bytes, pero también es posible que signifique 2^{20} bytes. Puede depender tanto del fabricante del dispositivo, como que nos estemos refiriendo, como RAM, hardware de red, ...etc.

Para hacernos una idea del volumen de datos que maneja la humanidad, según el volumen de **datos en el mundo** se calculaba en unos **4.4 zettabytes en 2013**, teniendo para el **año 2025 163 zettabytes**.

Unidades	Significado
Bit	Unidad mínima de información en un sistema de computación (almacena un "0" o un "1").
byte (B)	8 bits
kilobyte (kB)	1000 bytes (10^3 bytes)
megabyte (MB)	1000 kilobytes (10^6 bytes)
gigabyte (GB)	1000 megabytes (10^9 bytes)
terabyte (TB)	1000 gigabytes (10^{12} bytes)
petabyte (PB)	1000 terabytes (10^{15} bytes)
exabyte (EB)	1000 petabytes (10^{18} bytes)
zettabyte (ZB)	1000 exabytes (10^{21} bytes)
yottabyte (YB)	1000 zettabytes (10^{24} bytes)

Figura 1.1: Unidades de cantidad de información

Hay que tener en cuenta que **no hay una cantidad fija** a partir de la cual se pueda considerar que el problema es Big Data. Simplemente nos quedaremos con que los sistemas de Big Data manejan del orden de **petabytes** (PB) o **exabytes** (EB). Pero y, ¿de dónde vienen todos estos datos? Algunas de las **principales fuentes** de estos datos son:

- Datos de **usuarios y/o clientes** de instituciones y empresas.
- Datos generados por **transacciones** (compras, transferencias,...)
- Datos adquiridos por **sensores** (temperatura, humedad, ...)
- Datos subidos a **redes sociales** (fotos, textos, ...)
- Datos relacionados con la salud (historiales, resultados, ...)
- Datos de geolocalización (GPS)
- Datos guardados en logs (accesos a web, de aplicaciones, ...)
- Datos producidos por le internet de las cosas (dispositivos IoT)
- Datos producidos por las ciencias (experimentos, genómica, meteorología, ...)
- Datos producidos por cámaras (imágenes, videos, ...)
- Datos Open Data (datos liberados o abiertos por instituciones)

Mención especial requieren los **datos abiertos**, ya que son una fuente interesante de datos. Podemos consultar más información en su entrada de Wikipedia. En concreto, en España, podemos encontrar la web del gobierno del España relativa a este proyecto, donde podemos encontrar todos los datos liberalizados por el gobierno los diferentes gobiernos de España.

1.1.1.2. Velocidad

No solo es relevante la cantidad de datos con los que tratamos, sino que también es importante la **velocidad a la que se producen**. Para hacernos una idea, se calcula que en el **mundo se general** cada **60 segundos**:

- 350.000 tweets
- 300 horas de video subido a YouTube
- 171 millones de correos electrónicos
- 330 GBs de información generados por sensores

Si volvemos a revisar la lista de fuentes de datos del punto anterior y tenemos en cuenta que en el mundo hay 7870 millones de personas (datos de 2022), podemos hacernos una idea de la velocidad a la que se generan los datos cada minuto que pasa. Y el problema no es solo a la velocidad a la que se generan los datos, sino que hay que procesarlos e integrarlos a igual velocidad.

A raíz de esto, se han creado nuevas estrategias como el **procesamiento tipe streaming**, del que hablaremos más adelante.

1.1.1.3. Variedad

Además, de la cantidad de datos y la velocidad a la que se generan, existe el problema de la **variedad de datos** que se generan, en lo relativo a su representación. Dentro de esta variedad, podemos encontrar los siguientes grupos:

- **Datos Estructurados**

  Los datos estructurados son aquellos que **existen en bases de datos**, los cuales existen dentro de tablas con una estructura bien definida que nos indica que tipo de datos es cada una de las columnas.

- **Datos No Estructurados**

  Son aquellos que no se rigen por un esquema, como pueden ser **vídeos**, **imágenes** o **audios.**

  Hay que tener en cuenta que la proporción de datos no estructurados del mundo se estima que sean sobre un 80 % de los datos totales, lo cual se debe a la naturaleza de éstos datos. Solo hay que comprar el espacio de almacenamiento que ocupa un vídeo o una canción en comparación con el que ocupa un registro en una base de datos.

- **Datos Semiestructurados**

  Son datos definidos con una cierta estructura pero que no tienen una naturaleza relacional, como en una base de datos. Por lo general se almacenan en ficheros de texto siguiendo un formato preestablecido, de modo que mantienen la flexibilidad que ofrece el fichero, a la vez que es posible determinar que significa cada una de las porciones de información que se encuentran en el mismo.

  Algunos ejemplos de este tipo de ficheros son: **CSV**, **XML** y **JSON**.

- **Metadatos**

  Los metadatos son datos extra, que se generan de forma automática a veces, y que contienen **información sobre los propios datos**. Algunos ejemplos de la información que se pueden almacenar son los siguientes:

- Información sobre la estructura del dato.
- Fuente.
- Autor.
- Fecha de creación.
- Resolución en pixeles (imágenes o vídeos).
- Duración (vídeos).
- Tasa de muestreo (audio).
- Tipo de compresión.

Estos son algunos, aunque los metadatos pueden almacenar cualquier tipo de información que nos pueda ayudar a interpretar los datos que se han almacenado.

1.1.1.4. Veracidad

Un problema extra con el que hay que tratar es que los datos no siempre cuentan con la calidad deseada o no son **totalmente fieles a la realidad**.

Este concepto esta íntimamente ligado con el concepto de **señal/ruido** en el flujo de información. El **ruido** son datos que no pueden ser convertidos en información, mientras que la **señal** esta constituida por los datos que sí se pueden convertir en información.

Así, por un lado, es necesario conocer en que condiciones se adquirieron los datos, para poder estimar su veracidad, mientras que en otras situaciones será necesario realizar un procesamiento específico de los mismos con el fin de resolver posibles problemas o eliminar información no válida (ruido).

Por norma general, los datos generados de forma automática contienen menos ruido que los que producen las personas.

1.1.1.5. Valor

La última de las 5 Vs es el **valor**, concepto ligado a cómo de útiles son los datos para una institución, empresa o persona, y que esta íntimamente ligado con el concepto de **veracidad**, ya que cuanto más veraces sean los datos más valor se puede obtener de ellos.

También depende en gran medido del **tiempo transcurrido** desde que se produjeron esos datos. Por ejemplo, si estamos operando en bolsa, los datos sobre el valor de las acciones tiene mucho valor si se han generado hace 1 segundo que si se lo han hecho hace 10 minutos. En este aspecto, cuanto más rápido se hagan llegar los datos desde donde se producen hasta donde se toman las decisiones, mas valor tendrán.

Es importante, además, que los datos sean **lo más completos posible** para poder producir el valor deseado. Es decir, además de ser veraces deberán estar completos, incluyendo todo lo que se necesita para interpretar correctamente lo que representan.

Por último, la **propia interpretación del dato** también juega un papel vital. Sería absurdo, por ejemplo, tener almacenadas las temperaturas de un sensor que esta debajo de tierra e intentar usar esos datos para predecir la temperatura ambiente. En este caso, aunque el dato es veraz y completo, la interpretación estaría siendo errónea.

1.1.2. Que Conseguimos Gracias al Big Data

En esta sección vamos a ver que nos aporta, no solo obtener y almacenar grandes cantidad de datos, sino también poder tratarlos y analizarlos gracias a las tecnologías de Big Data.

Las **metodologías para Big Data** nos permiten realizar diversas operaciones con grandes cantidades de datos, entre las cuales se encuentra:

- Capturarlos desde sus orígenes.
- Integrarlos para poder almacenarlos de forma unificada.
- Almacenarlos de un modo distribuido y replicado, consiguiendo alta disponibilidad.
- Tratarlos de forma distribuida usando un gran numero de máquinas que los procesan en paralelo.
- Aplicar técnicas de minería de datos para crear modelos predictivos.
- Usar esos modelos para realizar predicciones a utilizar en sistemas automáticos.
- Crear visualizaciones y cuadros de mando usando tanto los propios datos como los modelos creados con ellos.

Como vemos, hay muchas operaciones que podemos realizar en los sistemas de Big Data. Estas operaciones, nos ofrecen un conjunto de **beneficios**, entre los que podemos destacar:

- Generar registros mas detallados mediante la integración desde diversas fuentes.
- Optimizar las operaciones de instituciones y empresas.
- Identificar nuevos mercados.
- Realizar predicciones basándonos en los modelos generados por los datos.
- Detectar casos de fraude e impagos.
- Dar soporte a la toma de decisiones.
- Realizar descubrimientos científicos.
- Ayudar a los médicos a detectar enfermedades en los pacientes.

1.1.2.1. Desde los Eventos al Valor

El tratamiento de los datos a través de diversas capas de procesamiento nos permite llegar desde los eventos que generaron esos datos hasta la sabiduría que nos permite tomar mejores decisiones. El camino que recorren en ese proceso los datos es el siguiente:

1. **Eventos**: en nuestro mundo se producen diferentes tipos de eventos, como una estación meteorológica que toma datos, una cámara que captura una foto o alguien que realizar un pago con tarjeta.
2. **Datos**: estos eventos se reflejan, de algún modo, generándose los datos que pueden ser almacenados en registros de bases de datos o ficheros para su posterior uso.
3. **Información**: cuando le damos contexto a los datos y los organizamos de algún modo lógico, tenemos información, como los distintos registros del pago con una tarjeta almacenados.

4. **Conocimiento**: si tratamos la información, dándole un significado, podemos obtener conocimiento, por ejemplo, generando modelos mediante los cuales se puede representar la realidad y que pueden ser usados para realizar predicciones.
5. **Sabiduría**: si una vez teniendo el conocimiento generado añadimos el entendimiento necesario para saber como utilizarlo, podemos considerar esto sabiduría.
6. **Valor**: si realizamos acciones basándonos en esta sabiduría, esas acciones serán mejores que las podemos realizar sin basarnos en los datos, consiguiendo entonces valor añadido.

A pesar de que dentro de las tecnologías de Big Data se suele englobar lo relacionado con obtener valor del dato, en la práctica son la Minería de Datos y al Ciencia de Datos las disciplinas que terminan de obtener el valor.

La **Minería de Datos** es una rama de la Inteligencia Artificial que emplea técnicas de aprendizaje automático para obtener valor de los datos, mientras que la **Ciencia de Datos** en el fondo es la misma minería de datos pero haciendo énfasis en que se realiza en entornos de Big Data.

A pesar de ello, puedes encontrar estos términos siendo empleados de forma equivalente.

1.2. Clusters de Computadoras

Un **clúster de computadoras** es un conjunto de computadoras conectados entre si mediante una red para trabajar de forma conjunta como una única unidad resolviendo cargas de trabajo de forma conjunta.

Históricamente los clusters se construían empleando computadoras especializadas muy costosa, sin embargo, mas adelante han ido apareciendo diferentes frameworks o plataformas de computación distribuida que emplean computadoras de us común, gracias al aumento de sus prestaciones.

El uso de clusters ofrece ventajas respecto al uso de computadoras individuales. Dichas ventajas son las siguientes:

- **Alto Rendimiento**

  Cada elemento del cluster es una **computadora completa**, con sus recursos propios (memoria, procesador y almacenamiento), las cargas de trabajo susceptibles de paralelización puede acelerarse dividiéndose en subtareas y distribuyéndose para que sean ejecutadas en diferentes nodos. Esto permite resolver problemas más complejos en menos tiempo.

- **Alta Disponibilidad**

  Cuando uno nodo o un conjunto de ellos falla, se pueden tomar medidas para garantizar la **disponibilidad de los servicios** o **datos** que hay en esas máquinas. Esto se lleva acabo arrancado de nuevo el nodo, utilizando otro para suplirlo o respondiendo a las peticiones desde otros nodos.

- **Equilibrado de Cargas**:

  El equilibrado se consigue mediante algoritmos específicos que **distribuyen la carga** de trabajo entre los diversos nodos del clúster para evitar cuellos de botella. Tales cuellos de botella se producen cuando el envío de trabajos a nodos sobrecargados aumenta la latencia media con la que tales trabajos son finalizados.

  Para ello, se realiza una **monitorización del estado de carga** de cada nodo y se decide para cada paquete de trabajo a que nodo enviarlo, atendiendo al tamaño del trabajo, la carga del nodo y la potencia de procesamiento de cada nodo.

- **Escalabilidad**

  Gracias a que el cluster está formado por un **número indeterminado de nodos**, no solo conseguimos una mayor potencia de cálculo, sino que podemos **incrementar esta potencia** de cálculo **añadiendo nuevos nodos**. Es decir, la potencia de cálculo del cluster es ampliable.

  Esta característica es muy deseable para sistemas de Big Data, ya que desaparece la necesidad de una estimación de potencia necesaria a priori. Con un cluster escalable podemos comenzar con un número determinado de nodos he ir ampliando según se vaya necesitando.

  Podemos encontrar dos tipos de escalado diferente:

  - **Escalado Vertical (scale-in)**

    Es el que se consigue mejorando las características hardware de las computadoras donde se están ejecutando las cargas de trabajo. Este escalado esta limitado por las especificaciones hardware de los nodos que componen el cluster.

  - **Escalado Horizontal (scale-out)**

    Es el que se consigue añadiendo más nodos al cluster. Es el escalado que realmente más influye en la escalabilidad de los dos.

1.3. Conceptos de Almacenamiento de Datos

En este apartado vamos a ver diferentes **conceptos fundamentales** del **almacenamiento de datos**. Veremos lo que son las base de datos relacionales, lo que es un dataset o un almacén de datos. Así mismo veremos las algunos conceptos teóricos con las propiedades ACID o el teorema de CAP.

1.3.1. Bases de Datos Relacionales

Una base de datos relacional es una **almacén de información** que almacena registros dentro de tablas. Estas **tablas** están compuestas de filas (registros) y de columnas (atributos). Para cada tabla se define un **esquema**, en el cual se define que atributos tiene cada registro y de que tipo son.

Gracias a la **uniformidad de los datos** que hay en cada tabla, los motores de bases de datos relacionales pueden ofrecer un altísimo rendimiento a la hora de realizar búsquedas. Tales búsquedas pueden realizarse en una tabla o en varias, a través de las relaciones existentes entre las diferentes tablas.

Una de las características clave de las bases de datos relacionales para su alto rendimiento es su capacidad de generar índices sobre columnas de tablas, lo que acelerá tanto la búsqueda de elementos dentro de la tabla como en el enlazado de registros de las distintas tablas que están relacionadas.

Hay que tener en cuenta que las bases de datos relacionales **no están preparadas** para distribuir tablas entre diferentes nodos o servidores, por lo que **no son las solución más idónea para Big Data**, ya que limitan la escalabilidad del sistema.

1.3.2. Dataset

Un **dataset** es una colección de datos que guardan una cierta relación entre ellos. Suelen **almacenarse** en ficheros planos, como CSV, XML o JSON, aunque también pueden hacerlo en bases de datos, o en archivos multimedia. Algunos ejemplos de dataset son:

- Una colección de tweets.
- Una colección de posts.
- Una colección de imágenes.
- La serie de registros de una base de datos relacional.
- La sucesión de medidas de una estación meteorológica.

1.3.3. Almacén de Datos

Un almacén de datos es un **repositorio central de datos** a nivel institucional o empresarial, dentro del cual se almacenan tanto datos actuales como históricos.

Se emplean tanto para la **inteligencia de negocio** (BI) como para realizar consultas analíticas, por lo que además de tener tablas relacionales, también suele incluir OLAP.

Por norma general sus datos son cargados periódicamente desde sus fuentes mediante procesos de tipo ETL. Esto significa que la información que contienen es por lo general **una instantánea** del estado general de los datos en un **determinado momento**, por lo que es un almacenamiento que no se va emplear para el uso de transacciones, sino para inteligencia de negocios o analítica.

1.3.4. ACID

ACID es el **principio fundamental de diseño** de las bases de datos de que se crean para el uso transaccional. Esta formado por 4 características de obligado cumplimiento, correspondiendo cada una de ellas al las letras del acrónimo:

- **Atomicidad** (Atomicy):

  La automicidad implica que las operaciones realizadas sobre la base de datos o bien tienen éxito, o fallan por completo. Por ejemplo, si una transacción consiste en escribir dos registros y la primera inserción es exitosa pero la segunda falla, el motor de la base de datos no consolida la primera operación.

- **Consistencias** (consistency)

  La consistencia nos asegura que la base de datos siempre es vista desde fuera en un estado consistente, comprobando siempre que los datos cumplen con los esquemas y restricciones de las tablas antes de escribirlos en ellas. Gracias a esto, cualquier base de datos en un estado consistente, sigue en este estado después de una transacción.

- **Aislamiento** (isolation)

  El aislamiento nos asegura que el resultado de una transacción no es visible por otras operaciones hasta que se ha completado. Esto significa que si una transacción consiste en insertar 2 registros, ningún otro usuario podrá hacer una selección donde solo aparezca el primero de ellos. Verá ambos si la transacción ha finalizado o ninguno en caso contrario.

- **Durabilidad** (durability)

  La durabilidad nos asegura que los resultados escritos en la base de datos sin permanentes. Esto implica que tales estructuras no se pierden en caso de que la maquina se apague tras realizar una

transacción, lo cual se consigue almacenando la información en un sistema de almacenamiento no volátil.

Este tipo de gestión realiza un control pesimistas de la concurrencia, dando por hecho que cualquier problema que pueda ocurrir, ocurrirá tarde o temprano, por poco probable que sea.

Para conseguirlo, el motor de la base de datos bloque registros o incluso tablas enteras en determinados momentos para asegurar la consistencia de los datos.

1.3.5. Teorema CAP

El **teorema CAP**, también conocido como **conjetura de Brewer**, establece que una base de datos distribuida sólo puede cumplir como máximo con 2 de las 3 siguientes propiedades:

- **Consistencia** (Consistency)

  Todos los nodos de la red ven los mismos datos al mismo tiempo. Cualquier lectura realizada siempre muestra el estado posterior a la ultima escritura realizada o un error. Es decir, la base de datos tiene permitido devolver un error en caso de no pueda devolver el estado más actual.

- **Disponibilidad** (Avaibility)

  Toda petición recibe una respuesta no errónea, sin la garantía de que el estado observado sea el correspondiente a la última escritura en algún nodo de la base da datos.

- **Tolerancia al Particionamiento** (Partition tolerance)

  El sistema sigue funcionando y produciendo respuestas aún en caso de que se haya perdido la conexión con/entre algunos nodos, lo cual implica qeu se pueden recibir lecturas desde unos nodos que no incluyan información escrita en otros.

En otras palabras, el teorema implica que **nunca se puede cumplir A+B+C**, sino que habría que escoger entre C+A, C+P o A+P, a la hora de diseñar una base de datos distribuida. Esto también implica que a la hora de seleccionar una base de datos distribuida en primer lugar tendremos que decidir cuales de las 3 características estamos dispuestos a prescindir, y asegurarnos de que la base de datos cumple con las 2 características de las cuales no prescindimos.

Para demostrar la razón por la que sólo 2 de las propiedades de las 3 del teorema de CAP se pueden cumplir a la vez en una base de datos distribuida tenemos que contemplar los siguiente escenarios:

- Si se requiere **consistencia** (C) y **disponibilidad** (A), los nodos necesitan estar comunicados para asegurar la consistencia y poder devolver siempre respuestas que no sean error. Por lo tanto, asegurar la tolerancia del particionamiento (P) no es posible, ya que no se puede garantizar que no haya fallos de red entre los nodos.

- Si se quiere **consistencia** (C) y **tolerancia** (P), los nodos no pueden mantenerse disponibles (A) durante el tiempo necesario hasta que termine el particionamiento y vuelva a alcanzarse un estado consistente (C) entre ellos.

- Si se quiere **disponibilidad** (A) y **tolerancia al particionamiento** (P), entonces la consistencia (C) no es posible debido a la necesidad de comunicación entre los nodos para que ésta se mantenga. En otras palabras, si se quiere mantener disponible la base datos en momentos de particionamiento, es obligatorio aceptar lecturas inconsistentes.

1.3.6. BASE

BASE es un principio de diseño de bases de datos basado en las restricciones impuestas por el teorema de CAP, y típicamente empleado por muchas implementaciones de bases de datos distribuidas. El acrónimo vienen de los principios que rigen esta estrategia de diseño:

- **Básicamente disponible** (basically available)

  Significa que la bases de datos siempre responde a las solicitudes recibidas, ya sea con una respuesta exitosa o con una notificación de error, aún en caso de que se produzca el particionamiento entre los nodos. En determinadas ocasiones, esto implica recibir lectoras desde nodos donde no se han registrado las últimas escrituras, por lo que el resultado no es consistente.

- **Estado Blando** (soft state)

  Implica que la base de datos puede encontrarse en un estado inconsistente cuando se realiza una lectura. De modo, que se puede realizar 2 veces la misma lectura y recibir resultados diferentes, a pesar de que no haya habido ninguna lectura entre ellas.

  En otras palabras, en cada momento sólo tenemos cierta probabilidad de estar viendo el estado final de la base de datos, porque puede haber escrituras que aún no se hayan consolidado en el nodo sobre al que se realiza la lectura.

- **Eventualmente consistente** (eventually consistency)

  Significa que tras cada escritura, la consistencia solo se logra cuando el cambio se ha propagado por todos los nodos. Durante el tiempo que tarda en producirse la consistencia, observamos el estado blando en la base de datos.

Por norma general, una base de datos que **conforme a la filosofía BASE** prefiere la **disponibilidad** antes que la consistencia, es decir, desde el punto de vista del teorema CAP, A+P.

1.4. Conceptos de Procesamiento de Datos

Una vez vistos los conceptos de almacenamiento, en esta sección vamos a ver los **conceptos de procesamiento de datos** relacionados con el Big Data y que es importante conocer. Entre otros, veremos el procesamiento en paralelo y distribuido, estrategias de procesamiento de datos, OLTP, OLAP y el principio de SCV.

1.4.1. Procesamiento en Paralelo

El procesamiento en paralelo tiene que ver con las capacidad de los sistemas operativos modernos de realizar varias tareas al mismo tiempo.

Los **sistemas multitarea** existen desde mucho tiempo antes de que comenzasen a aparecer los procesadores multihilo o las placas base multiprocesador. Para ello, se cuenta con un gestor de procesos que se encarga de repartir el tiempo de ejecución de los diversos procesos que se estén ejecutando en el sistema.

Gracias a la aparición de las placas base multiprocesador, los sistemas operativos instalados en las máquinas con tales placas pudieron tener hardware disponible como para poder realizar más de una tarea al mismo tiempo.

Más adelante, con la aparición de los **procesadores multihilo** y **multinúcleo**, por fin la multitarea pudo llegar al usuario convencional. Mientas que los **procesadores multinúcleo** contienen varios procesadores, los **multihilo** son capaceas de atender más de un hilo de ejecución, permitiendo al segundo utilizar recursos que no se estén empleando en ese momento. Puede darse la situación de 2 procesos puedan requerir usar el mismos recurso al mismo tiempo, por lo que habrá fracciones de tiempo en los que un hilo se quedará parado.

Es decir, que **no es equivalente** un procesador con 2 núcleos y 4 hilos a un procesador con 4 núcleos.

Cuando la **tareas** que se están ejecutando **son independientes**, por ejemplo reproducir un video y ejecutar un editor de textos, no existe ningún problema de paralelización entre ellas.

El **problema en cuanto a parelización** aparece cuando tenemos una **tarea muy compleja** y necesitamos dividirla en distintas subtareas independientes, lo cual siempre no es posible.

En este aspecto, cabe destacar **2 tipos de tareas** diferentes, respecto a la paralelización:

- **Tarea Paralelizable**: son tareas que se pueden paralelizar sin problema, por ejemplo, si nos piden sumar mil millones de numeros, podemos separar esos números en tantos paquetes como queramos y ejecutar un proceso para cada uno de ellos en un procesador multinúcleo.
- **Tarea no Paralelizable**: son tareas que no se pueden paralelizar por su naturaleza, por ejemplo, tareas que requieren el resultado de un paso anterior paras poder usarlo en el siguiente, ya que aun separando la tarea en subtareas, una de ellas deberá esperar a que la anterior acabe, no habiendo un modo eficiente de paralelizarla.

1.4.2. Procesamiento Distribuido

El **procesamiento distribuido** esta muy relacionado con el procesamiento en paralelo, con la distinción de que en este caso, en vez de usar diferente hilos o procesadores dentro de una misma máquina, se lleva a cabo en distintas máquinas que se comunican en red formando un **clúster**.

A su vez, estás máquinas podrán tener **varios núcleos**, con lo que el procesamiento no solo se hace distribuido en nodos, sino que dentro de cada nodo se puede procesar en paralelo. Esto añade complejidad al sistema a la hora de determinar el modo eficiente de aprovechar este doble paralelismo. Afortunadamente, gracias a los **frameworks de Big Data** que podemos encontrar en el mercado, esta gestión se realiza de forma automática.

Hay que entender que para el los diferentes nodos e hilos puedan llevar a cabo su trabajo de forma eficiente tiene que haber diferentes métodos de comunicación entre los distintos procesos que se están ejecutando en paralelo. Toda comunicación de datos necesita su tiempo, algo que hay que tener en cuenta a la hora de diseñar un sistema de Big Data.

Dentro de los diferentes **tipos de comunicación** entre procesos que podemos encontrar en un sistema Big Data tenemos los siguientes:

- **Comunicación dentro de la misma máquina**

  Es el caso de comunicación más rápido posible, ya que los datos no necesitan ser enviados por red, sino que los procesos se pueden intercambiar información a trabes de los recursos de la propia máquina, como la memoria RAM, sistema de ficheros o una base de datos.

- **Comunicación entre dos máquinas dentro del mismo switch**

La comunicación entre máquinas a través de una red de comunicaciones siempre es varios ordenes de magnitud más lenta que si se realiza entre procesos de una misma máquina, ya que es necesario enviarla a través de la interfaz de red, usando los protocolos de comunicación que correspondan, y la otra máquina tiene que leer la información recibida desde su propia red.

Aunque es más lento, es tipo de comunicación es **obligatoria** en entornos de Big Data, los cuales se basan en el uso de distintos nodos dentro de un clúster.

Llegados a este punto, el modo más rápido de comunicación es que sean nodos **conectados al mismo switch**, ya que en ese caso la información necesita hacer un menor número de saltos entre elementos de red.

- **Comunicación fuera del switch**

  Cuanto más saltos entre switch necesite dar la información entre un nodo y otro mayor será el tiempo de comunicación.

  El número de **entradas de un switch es limitado**, por lo que por norma general los servidores dentro de un mismo rack suelen estar conectados mediante un switch, pero están conectados mediante otro switch a otros racks, implementándose una **jerarquía de switches**. El software que gestiona la infraestructura del clúster se configura con información acerca de esta jerarquía que se ha utilizado a la hora de realizar las conexiones físicas, de modo que pueda tomar las mejores decisiones a la hora de emplazar tanto datos como procesado en los nodos.

- **Comunicación fuera del CPD**

  Los nodos de un clúster estarán típicamente dentro del mismo CPD (Centro de Procesado de Datos), pero los **datos**, por norma general, **no se generan dentro de CPD**, sino fuera de éste, por lo que hace falta hacerlos llegar al clúster. De igual modo pasa con los resultados obtenidos en el CPD.

  Esta comunicación se realiza a una velocidad muy inferior al resto de comunicaciones que hemos visto.

1.4.3. Estrategias de Procesamiento de Datos

En los entornos de Big Data se emplean diferentes **estrategias para el procesamiento de datos**, las cuales se escogen según la cantidad y naturaleza de los mismos, así como las necesidades de la actividad que se esté realizando. Estas estrategias son:

- **Por lotes**

  En este tipo de procesamiento se reúne y almacena un grupo de datos para procesarlos todos juntos [1].El **procesamiento por lotes** (del ingles batch) se realiza sin la necesidad de producir respuestas a corto plazo. Pueden tardar en ejecutarse horas o incluso días. Se emplea mayormente para trabajo de analítica con gran cantidad de datos, en ocasiones, todos los disponibles para la tarea en cuestión.

- **Transaccional**

  En este tipo de procesamiento el tiempo de respuesta es muy importante, y es de obligatorio cumplimiento que éste sea muy corto, por lo que los datos se procesan al instante y se genera un respuesta de igual forma.

Este tipo de procesamiento es importante cuando se realizan transacciones. Debido a las restricciones en el tiempo de respuesta, este tipo de procesamiento no puede afectar a un gran volumen de datos.

- **En tiempo real**

  Al igual que en el caso anterior, esta estrategia requiere que el tiempo de respuestas sea incluso más corto. Se emplea en analíticas interactivas, en las que un usuario humano ésta consultando estadísticas acerca de los datos.

  Para poder realizarse con gran volumen de datos suelen emplear un subsistema OLAP, que veremos más adelante, en muchas ocasiones almacenadas en memoria.

  En muchas ocasiones escucharemos que el procesamiento transaccional ocurre en .[en] tiempo real", lo que es totalmente cierto. En otras palabras, "tiempo real"puede en la práctica emplearse tanto para procesamiento analítico como para actividades transaccionales.

- **Streaming**

  En procesamiento en sreaming tiene mucho que ver con el procesamiento en tiempo real porque debe tener un tiempo de respuesta muy corto, sin embargo, en este caso la clave es que debe **producirse a la velocidad** a la que se recibe el **flujo de entrada**, de ahí lo de streaming.

  Esto añada complejidad extra a los sistemas que han de diseñarse para ser capaces de procesar/analizar datos en streaming. Esto se debe a que las estructuras de datos en las que se mantiene al información necesaria para realizar la analítica deben ser capaces de actualizarse a medida que llegan nuevos datos. Por ello, la información necesita sera almacenada en memoria, lo que limita el tamaño máximo de datos que pueden tratarse a la vez.

1.5. OLTP

Empleamos el acrónimo **OLTP (Online Transaction Processing)** para designar un sistema que esta orientado a transacciones, por lo que trata con los datos operacionales del día a día, relacionados con acciones que necesitan realizarse en tiempo real.

Tales transacciones son por lo general realizadas contra bases de datos relacionales, incluyendo sólo acciones sencillas (insetar, actulizar, seleccionar y eliminar) sin ningún tipo de analítica, gracias a lo cual se consiguen tiempos de respuesta inferiores a un segundo, de modo que el sistema sea usable sin producir tiempos de espera desagradables para los usuarios.

1.5.1. OLAP

Se emplea el acrónimo **OLAP (On-Line Analytical Processing)** para designar a un sistema que esta orientado a procesar consultas de tipo analítico en tiempo real. Es tipo de sistemas son parte integral de la inteligencia de negocio (BI) y la minería de datos, usándose en **todos los niveles de la analítica de datos**.

Almacenan los datos ne bases de datos mutidimensionales, llamadas en ocasiones **cubos OLAP**, altamente optimizadas para poder responder en muy poco tiempo a consultas complejas que afectan a lo que en el mundo relacional serían varias tablas. Para obtener tal rendimiento, esta bases de datos **guardan los datos denormalizados**. En ocasiones se mantienen en la memoria RAM de la máquina que ejecuta el sistema, lo cual implica, como ya hemos comentado, que limita el tamaño de los datos a tratar.

1.6. Principio SCV

Mientras que el teorema CAP tiene que ver con el almacenamiento de datos distribuidos, el **principio SCV** esta relacionado con el **procesamiento distribuido** de los datos. Es decir, no tiene que ver con la escritura o lectura de los datos, sino con el procesamiento que se realiza sobre ellos dentro de los nodos de un sistema de procesamiento distribuido.

De modo similar a lo que ocurría con el teorema CAP, el principio SCV establece que un sistema de procesamiento distribuido solo puede soportar como máximo **2 de las siguientes 3 características**:

- **Velocidad** (Speed)

  Se refiere a cuanto **tarda en procesarse los datos** desde el momento que son recibidos en el sistema analítico. Por lo general se excluye el tiempo que se tarda en capturar los datos, considerando sólo lo que se tarda en en generar la estadística o ejecutar el algoritmo en cuestión.

  Esta velocidad es más alta si estamos ante un sistema de analítica en tiempo real que si se trata de un sistema por lotes.

- **Consistencia** (Consistency)

  Se refiere en este caso a la precisión de los resultados de la analítica. Tal **precisión** depende de si para la analítica se utilizan todos los datos disponibles (precisión alta) o si por el contrario se emplean técnicas de muestreo para seleccionar solo un subconjunto de éstos con la intención de producir resultados en menor tiempo, pero de menor precisión.

- **Volumen** (Volume)

  Se refiera a la **cantidad de datos que pueden ser procesadas**. Hay que tener en cuenta que en entornos Big Data, el alto volumen de datos es una característica siempre presente.

De igual modo que hicimos con el teorema CAP<, nos fijaremos en una serie de escenarios para mostrar que no podemos conseguir un sistema que cumpla a la vez las 3 características:

- Si se requiere **velocidad** (S) y **consistencia** (C), no podemos procesar un volumen (V) alto de datos, ya que esto aumenta el tiempo de respuestas.
- Si se quiere **consistencia** (C) y poder procesar **grandes volumenes de datos** (V), no es posible realizar el procesado a una alta velocidad (V).
- Si necesitamos procesar una **volumen gran de datos** (V) a una **alta velocidad** (V), entonces necesitaremos emplear técnicas de muestreo para seleccionar solo subconjuntos de datos, lo cual producirá un resultado no consistente (C).

Como vemos, la analogía entre el teorema CAP y el principio SCV es muy similar, simplemente se aplican a diferentes paradigmas, uno al almacenamiento y otro al procesamiento.

1.7. Arquitectura por Capas de Big Data

Al margen de que durante el proceso de diseño y desarrollo de cada proyecto de Big Data pueda optarse por la arquitectura que más convenga, de modo generalizado se emplea una arquitectura según la cual el flujo de datos va pasando por una serie de capas. Estas capas son:

- **Capa de Ingestión**

Como primer paso, los datos se obtiene de diferentes fuentes con las cuales debemos conectarnos de alguna forma. Hay que tener en cuenta que la mayoría de fuentes existen previamente al sistema de Big Data, por lo que será el sistema el que deberá adaptarse a ellas.

- **Capa de Colección**

  Una vez que se recolectan e interpretan todos los datos viene el momento de integrarlos y darles una estructura adecuada. Hay que tener en cuenta que las fuentes de datos pueden ser muchas y de naturaleza muy diversa, cada una emitiendo la información en un formato diferente, de modo que hay que unificarlos como un único conjunto de datos con sentido y dejarlos listos para su utilización.

- **Capa de Almacenamiento**

  Esta gran cantidad de datos, que da origen al concepto de Big Data, debe ser almacenada, para lo cual se emplean sistemas de almacenamiento distribuido especialmente diseñados para ellos.

- **Capa de Procesamiento**

  Es la capa que provee de infraestructura a la siguiente capa para poder tratar con la esta gran cantidad de datos. Es decir, facilita el procesamiento, ya sea por lotes, streamin, tiempo real, ...etc, pero únicamente hace lo que le esta pidiendo la capa de consulta y análisis.

- **Capa de Consultar y Analítica**

  Es la capa en la que se comienza a dar valor al dato, realizando la estadística, algoritmia o análisis que se considere oportuno, para ello siempre basándose en la capa previa de procesamiento.

- **Capa de Visualización**

  Es la capa con la que interacciona el usuario final, el cual puede consultar reportes estadísticos o acceder a cuadros de mandos interactivos con diversas visualizaciones y controles desde donde puede decidir que información quiere ver y como quiere verla. Desde esta capa es, por norma general, donde se toman las decisiones de negocio.

- **Capa de Seguridad**

  Capa transversal que da soporte a todo lo relacionado con la seguridad en los datos empleando métodos tanto físicos como de software. Incluye protección ante el ataque o uso malintencionado tanto desde dentro como desde fuera.

- **Capa de Monitorización**

  Capa transversas que da soporte a todo lo relacionado con la monitorización tanto de los datos como del propio sistema. La monitorización incluye auditoría, testo, gestión y control de modo que los datos empleados sean correctos y frescos. Tal monitorización es una parte importante de la gobernanza de datos.

Como vemos, el sistema por capas ayuda a distinguir entre los diferentes procesos de análisis de datos en Big Data, pudiendo tratar cada etapa de forma independiente. Como hemos comentado, ya depende de cada proyecto seguir esta arquitectura o adaptarla a sus necesidades concretas, aunque podemos considerar está el estándar.

Para ver la arquitectura de forma más gráfica, se incluye la siguiente captura.

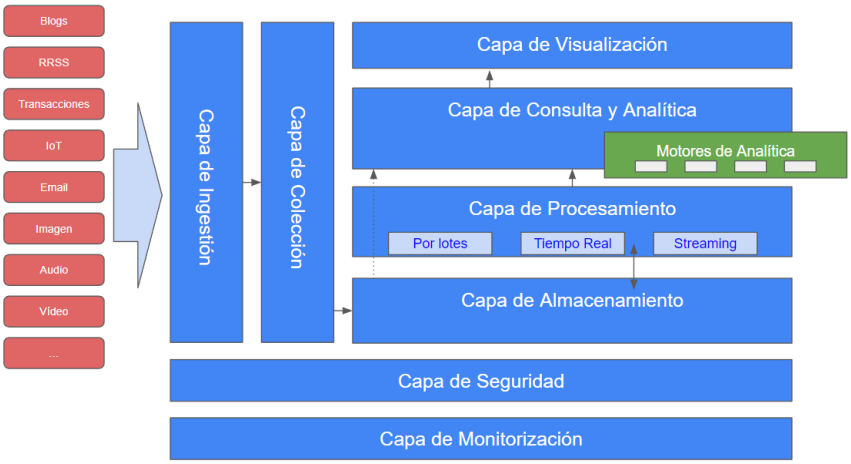


Figura 1.2: Capas de un sistema Big Data

1.8. Panorama del Big Data

Hablamos de panorama de Big Data (del ingles "The Big Data Lanscape") para referirnos a las diversas herramientas y utilidades que se pueden emplear para desarrollar proyectos de Big Data, muchas veces categorizadas según la capa de procesamiento a la que pertenece o según el tipo de actividad que realizan.

Desde los inicios del Big Data diversos autores han ido creando collages, unos mas detallados que otros, tratando de captura la riqueza de tal panorama. Aquí podemos ver uno de ejemplo, aunque si buscamos "big data lanscape.[en] nuestro navegador, podemos ver cientos de imágenes relativas al tema.



Figura 1.3: Panorama del Big Data

Al margen de esta imagen concreta, en la mayoría podemos encontrar, entre otras cosas, las siguiente tecnologías:

- **Hadoop** como la plataforma pionera del Big Data, enfocada al trabajo por lotes.
- Una gran **variedad de herramientas** pertenecientes al ecosistema de Hadoop, diseñada cada una de ellas para una función dentro de las distintas fases que componen el trabajo con los datos.
- **Spark**, como plataforma enfocada a procesamiento en tiempo real, capaz de interactuar con muchas de las herramientas ya disponibles en el ecosistema Hadoop.
- Bases de datos **NoSQL** y **NewSQL** como soluciones de almacenamiento para necesidades y casos específicos.
- Diversas **herramientas analíticas**, las pueden se pueden a su vez subclasificar.
- Diversas **herramientas de visualización**.
- Diversas **aplicaciones específicas** se nutre de o interactúan con alguna herramienta ya comentada.

Hay que tener en cuenta, que actualmente, el Big Data esta ampliando su campo de aplicación y realizando una transición, ya que además de seguir empleándose en ámbitos empresariales, esta siendo extensivamente usado en el campo de la **Inteligencia Artificial** y el **Machine Learning**, preparando los datos para entrenar modelos de IA o para que los sistemas predictivos puedan tratar con ellos.

Glosario

OLAP Online Analytical Procesing es una técnica empleada en la inteligencia de negocios para analizar grandes volúmenes de datos. 11

Referencias

[1] AWS - Batch Processing.
https://aws.amazon.com/es/what-is/batch-processing/.